
Redes Convolucionales – Grupo N°4



Reconocimiento de Lengua de Señas Americana (ASL)

Asignatura:

Inteligencia Computacional.

Año de Cursado:

2do Cuatrimestre de 2025.

Autores:

Di Liscia, Juan Francisco – jfdiliscia2015@gmail.com

Riboldi, Rodrigo Exequiel – rodrigorib41@gmail.com


Etapla 1 - 14/10/2025.....	3
1. Introducción.....	3
2. Configuración del entorno.....	3
5. Entrenamiento y Fine-Tuning.....	5
5.1. Fase 1.....	5
5.2. Fine-Tuning.....	5
6. Resultados cuantitativos.....	5
7. Reporte de Clasificación.....	5
8. Matriz de Confusión.....	7
Etapla 2 - 4/11/2025.....	10
Resultados.....	10
Consideraciones para mejorar.....	11
Etapla 3.....	12
Modelo Alternativo.....	12
Entrenamiento.....	12
Resultados de Pruebas en Video.....	13
Resumen cuantitativo por video – ResNet50.....	13
Resumen cuantitativo por video – MobileNetV2.....	14
Análisis cualitativo.....	14
Conclusión.....	15
Resumen del Modelo MobileNetV2 – Reconocimiento de Alfabeto ASL.....	15
2. Configuración general.....	15
3. Arquitectura del modelo.....	15
Base (feature extractor).....	15
Top personalizado (clasificador).....	16
Resumen estructural.....	16
4. Entrenamiento.....	16
Fase 1 – Clasificador superior congelando la base.....	16
Fase 2 – Fine-tuning (últimas 50 capas).....	17
• Video 1.....	17
• Video 3.....	17
Métrica agregada (los 3 videos juntos; 78 eventos = 26×3).....	18
Letras con desempeño consistente (destacados).....	18
Análisis cualitativo / causas probables.....	18
Conclusión breve.....	19

Etapa 1 - 14/10/2025

1. Introducción

El presente experimento tiene como objetivo **entrenar un modelo de clasificación de imágenes** basado en redes neuronales convolucionales (CNN) para reconocer las letras del **alfabeto de la Lengua de Señas Americana (ASL)**.

Se utilizó un enfoque de **transfer learning** con la arquitectura **ResNet50** pre-entrenada en *ImageNet*, adaptando su estructura para clasificar las 26 clases disponibles del dataset (letras A–Z más las clases especiales *del*, *nothing* y *space*).



2. Configuración del entorno

El modelo fue desarrollado en TensorFlow (Keras), utilizando aceleración por GPU para mejorar el rendimiento del entrenamiento.

Se habilitó el crecimiento dinámico de memoria GPU para evitar bloqueos de asignación de recursos.

Parámetros principales:

- Tamaño de imagen: 224x224 píxeles
- Batch size: 32
- Porcentaje de validación: 20%

- Optimizador: Adam
- Learning rate inicial: 0.001 (fase 1) y 1e-5 (fine-tuning)
- Épocas: 15 (fase 1) + 5 (fine-tuning)


3. Dataset

El dataset utilizado corresponde al ASL Alphabet Dataset, que contiene miles de imágenes organizadas por clase. Cada imagen representa una letra o símbolo del alfabeto en señas.

- Tamaño total del conjunto: 220.044 imágenes
- Número total de clases: 28

El dataset fue dividido en:

- Entrenamiento: 80% (176.036)
- Validación: 20% (44.008)



4. Arquitectura del modelo

El modelo se basó en ResNet50, eliminando su capa superior (`include_top=False`) y agregando un clasificador personalizado.

Estructura adicional aplicada:

1. Capa densa de 512 neuronas con activación ReLU
2. Segunda capa *Dropout*(0.3)
3. Capa de salida *Dense*(*num_classes*, *softmax*)

Parámetros totales: 24,651,164

- Entrenables: 1,063,452
- No entrenables (base pre-entrenada): 23,587,712

5. Entrenamiento y Fine-Tuning

5.1. Fase 1

Durante la primera fase, las capas convolucionales de ResNet50 permanecieron congeladas, entrenando únicamente las capas superiores agregadas.

5.2. Fine-Tuning

Posteriormente, se desbloquearon las **últimas 30 capas** del modelo base para refinar los pesos específicos al conjunto de datos.

Se redujo la tasa de aprendizaje a $1e-5$ para evitar sobreajuste.

El entrenamiento total converge rápidamente gracias al uso de transfer learning, alcanzando métricas de validación muy elevadas en pocas épocas.

6. Resultados cuantitativos

Métrica	Valor
Accuracy final	99.75%
Loss final	0.0081
F1-Score promedio	9.976

7. Reporte de Clasificación

El análisis detallado por clase muestra que todas las letras presentan valores de precisión y recall superiores al 95%, lo que refleja un desempeño sumamente consistente del modelo.


Clase	Precisión	Recall	F1-score	Support
A	0,9970	0,9988	0,9979	1688
B	0,9994	0,9994	0,9994	1661
C	0,9988	0,9994	0,9991	1636
D	0,9993	0,9952	0,9973	1460
E	0,9893	0,9930	0,9911	1576
F	0,9988	0,9994	0,9991	1658
G	0,9957	0,9981	0,9969	1617
H	0,9981	0,9969	0,9975	1617
I	0,9968	0,9994	0,9981	1582
J	1,0000	0,9994	0,9997	1551
K	0,9981	0,9968	0,9974	1563

L	0,9994	0,9994	0,9994	1582
M	0,9969	0,9950	0,9959	1600
N	0,9955	0,9955	0,9955	1564
O	0,9975	0,9994	0,9985	1628
P	0,9993	1,0000	0,9997	1517
Q	0,9994	0,9994	0,9994	1590
R	0,9994	0,9930	0,9961	1563
S	0,9937	0,9937	0,9937	1596
T	0,9950	0,9906	0,9928	1601
U	0,9944	0,9969	0,9956	1589
V	0,9980	0,9980	0,9980	1495
W	0,9981	0,9994	0,9987	1541
X	0,9970	0,9976	0,9973	1653
Y	0,9976	0,9994	0,9985	1688
Z	1,0000	1,0000	1,0000	1488
del	1,0000	0,9992	0,9996	1324
space	1,0000	0,9993	0,9996	1380

Esto confirma que el modelo no presenta sesgos significativos hacia clases particulares y mantiene una alta precisión general.

8. Matriz de Confusión

La matriz de confusión muestra una fuerte diagonal principal (predicciones correctas), con errores casi inexistentes entre clases.





Interpretación:

- La mayoría de los valores se concentran en la diagonal principal.
- No se observan patrones de confusión sistemática entre letras visualmente similares.

9. Gráficos de Entrenamiento

Evolución del Accuracy y Loss



Observaciones:

- El modelo alcanza una rápida convergencia en menos de 10 épocas.
- No se evidencia sobreajuste, ya que las curvas de entrenamiento y validación se mantienen muy próximas.
- Durante el *fine-tuning*, la precisión mejora marginalmente, refinando detalles en la clasificación.

Etapla 2 - 4/11/2025

En esta segunda etapa, el objetivo fue utilizar el modelo entrenado en la Etapa 1 y aplicarlo en un escenario más dinámico: la detección de señas en un archivo de video.

Mientras que la Etapa 1 se centró en *entrenar* el modelo con imágenes estáticas y bien definidas, esta etapa se enfocó en *implementar* ese modelo, resolviendo los desafíos que presenta un video.

El sistema desarrollado realiza los siguientes pasos clave:

1. Detección de la Mano: Se utilizó la herramienta *MediaPipe* de Google para analizar cada fotograma del video. Esta herramienta es capaz de localizar con gran precisión la mano del usuario y los puntos clave de sus articulaciones (nudillos, puntas de los dedos, etc.). Este paso es fundamental para saber *dónde* en la imagen se encuentra la seña.
2. Extracción y Adaptación: Una vez localizada la mano, el sistema recorta esa región específica de la imagen. El script se asegura de que este recorte también sea perfectamente cuadrado y que el tamaño coincida con el tamaño de las imágenes con las que fue entrenado el modelo, añadiendo márgenes si es necesario para evitar que la imagen se distorsione. Luego, ajusta su tamaño al requerido por el modelo antes de enviarlo para el análisis.
3. Predicción y Suavizado: El recorte cuadrado de la mano se envía al modelo ResNet50 cargado. Sin embargo, en un video, las predicciones pueden "parpadear" o cambiar rápidamente entre fotogramas. Para solucionar esto, se implementó una técnica de suavizado (smoothing):
 - El sistema no muestra la predicción de *un solo* fotograma.
 - En su lugar, almacena las últimas 10 predicciones en una cola.
 - La letra que finalmente se muestra en pantalla es la que aparece con *más frecuencia* en esa cola. Esto da un resultado mucho más estable y legible para el usuario.

4. **Visualización:** Finalmente, el sistema vuelve a mostrar el video, pero esta vez dibujando sobre la imagen los puntos de la mano detectados por *MediaPipe* y, lo más importante, mostrando la letra estabilizada que el modelo ha reconocido.

Esta etapa demuestra cómo el modelo teórico con 99.75% de precisión puede integrarse exitosamente en una aplicación práctica para interpretar lenguaje de señas en tiempo real o desde un video grabado.

Resultados

A pesar de que el entrenamiento del modelo en la Etapa 1 arrojó resultados de precisión sobresalientes, la aplicación práctica sobre video presentó desafíos que no se habían manifestado con las imágenes estáticas.

Discrepancia en el Desempeño

Se observó que la alta precisión del entrenamiento no se tradujo directamente al escenario del video. En la práctica, el sistema logró predecir correctamente y con alta confianza (definida en el script como superior al 85%) aproximadamente el 60% de las señas en los videos de prueba. El 40% restante o se predecía con una confianza baja (lo que dificulta su fiabilidad) o era clasificado de forma incorrecta.

Análisis de la Causa

La principal hipótesis para explicar esta diferencia es la falta de variabilidad en el dataset original con el que se entrenó el modelo.

El conjunto de datos, si bien era extenso, parecía carecer de suficientes ejemplos desde diferentes ángulos o perspectivas. Un caso claro se observó con la letra 'C':

- En el dataset de entrenamiento, la mayoría de las imágenes de la letra 'C' (como la visible en la página 2 del informe) mostraban la mano de perfil.
- Sin embargo, en uno de los videos de prueba, el usuario realiza la seña 'C' mostrando la mano de frente a la cámara.

Dado que el modelo no fue entrenado con suficientes ejemplos de esta perspectiva frontal, no pudo generalizar y, por lo tanto, falló en reconocer la seña correctamente en esa situación. Esto sugiere que, para una implementación futura más robusta, el modelo necesitaría ser re-entrenado con un conjunto de datos que incluya una mayor diversidad de ángulos, iluminaciones y variaciones en la ejecución de cada seña.

Consideraciones para mejorar

Para abordar la discrepancia entre el entrenamiento y la aplicación real, se han identificado varias líneas de acción:

1. Aumento de Datos (Data Augmentation)

Se realizó una búsqueda de datasets públicos alternativos. Sin embargo, se constató que la mayoría de los conjuntos de datos disponibles gratuitamente carecen de la variabilidad de ángulos y perspectivas que identificamos como necesaria.

Dado que encontrar un dataset más robusto no es viable de momento, la principal consideración a futuro es aplicar técnicas de Data Augmentation (aumento de datos) sobre el conjunto existente. Esto implicaría generar artificialmente nuevas imágenes de entrenamiento aplicando transformaciones como rotaciones leves, pequeños giros 3D y cambios de perspectiva, forzando al modelo a aprender a reconocer las señas independientemente del ángulo de la cámara.

2. Revisión del Fine-Tuning

Se planea realizar una revisión más profunda de la estrategia de fine-tuning del modelo ResNet50. Investigaremos si descongelar un número diferente de capas, o capas distintas a las últimas 30, puede tener un impacto positivo en la capacidad de generalización del modelo. El objetivo es encontrar un balance donde el modelo se adapte a las señas sin memorizar las perspectivas específicas del dataset de entrenamiento.

3. Verificación del Procesamiento de Entrada

Finalmente, se llevará a cabo una revisión exhaustiva del pipeline de procesamiento de imágenes en el script de vídeo. Es crucial asegurar que la imagen que se extrae del fotograma del video y se envía al modelo (recorte, cambio de tamaño, normalización) siga exactamente el mismo formato y los mismos pasos de preprocesamiento que se utilizaron durante la Etapa 1. Cualquier mínima desviación en este proceso podría ser una fuente de error en las predicciones.

Etapa 3

Modelo Alternativo

Con el objetivo de evaluar el desempeño de una arquitectura distinta y eficiente, se desarrolló un modelo alternativo basado en MobileNetV2.

Las configuraciones de los parámetros de entrenamiento ,tamaño de las imágenes (224×224 píxeles), batch size (32) y división de los datos (80% entrenamiento, 20% validación), se mantuvieron idénticas

a las del modelo basado en ResNet50, con el fin de garantizar una comparación directa y controlada entre ambas arquitecturas.

Entrenamiento

El proceso de entrenamiento se llevó a cabo en dos fases:

- Fase 1: se congeló la base convolucional de MobileNetV2 y se entrenaron únicamente las capas superiores añadidas, utilizando el optimizador Adam con la misma tasa de aprendizaje inicial empleada en el modelo anterior.
- Fase 2 (Fine-Tuning): se descongelaron las últimas 50 capas de la base pre-entrenada y se redujo la tasa de aprendizaje a 1×10^{-5} , manteniendo el entrenamiento durante 5 épocas, dado que el modelo mostró convergencia temprana.

Los resultados obtenidos durante el entrenamiento del modelo basado en MobileNetV2 fueron comparables a los alcanzados por la arquitectura ResNet50. El modelo logró una precisión (accuracy) final cercana al 98% y un valor de pérdida (loss) de aproximadamente 0.01 en el conjunto de validación. El F1-Score promedio también fue similar, aproximadamente un 98%, y el recall y precisión se mantuvieron similares. La única diferencia significativa entre ambas arquitecturas presentadas, es la arquitectura del modelo base.

MobileNetV2 mantiene un desempeño competitivo, conservando una alta capacidad de clasificación dentro del dominio del alfabeto de señas estadounidense (ASL).

Resultados de Pruebas en Video

Se probó el modelo que usa de base ResNet50 sobre 3 videos distintos. Para cada letra A–Z el equipo anotó si el modelo la reconoció correctamente en el video (“Si”), si no la reconoció (“No”) o si la reconoció con baja confianza (“Impreciso”; confianza < 60%).

Resumen cuantitativo por video – ResNet50

(26 letras por video)

Resnet50:

- Video 1:
 - Si: $14 / 26 = 53.85\%$.
 - Impreciso: $3 / 26 = 11.54\%$.
 - No: $9 / 26 = 34.62\%$.
- Video 2:
 - Si: $12 / 26 = 46.15\%$.
 - Impreciso: $5 / 26 = 19.23\%$.
 - No: $9 / 26 = 34.62\%$.
- Video 3:
 - Si: $12 / 26 = 46.15\%$.
 - Impreciso: $4 / 26 = 15.38\%$.
 - No: $10 / 26 = 38.46\%$

Si consideramos como “correctas” sólo las predicciones con etiqueta *Si* (criterio estricto), las precisiones por video están entre 46.15% y 53.85%. Si sumamos *Si* + *Impreciso* (criterio permisivo), las tasas suben a aproximadamente 61–65%.

Resumen cuantitativo por video – MobileNetV2

- Video 1:
 - Si: $17 / 26 = 65.38 \%$
 - Impreciso: 0
 - No: $9 / 26 = 34.62 \%$
- Video 2:
 - Si: $18 / 26 = 69.23 \%$

- Impreciso: $3 / 26 = 11.54 \%$
- No: $5 / 26 = 19.23 \%$
- Video 3:
 - Si: $18 / 26 = 69.23 \%$
 - Impreciso: $1 / 26 = 3.85 \%$
 - No: $7 / 26 = 26.92 \%$

Utilizando las consideraciones anteriores, las predicciones “correctas” (criterio estricto) están en 70.5%. Las predicciones donde tenemos más tolerancia a la baja confianza la tasa sube a 75.6%.

Análisis cualitativo

Persisten confusiones estructurales: P/Q, M/E, N/S son pares problemáticos. Son gestos similares en configuración de dedos o palma. Existe una falta de diversidad angular y perspectiva, algunos de los errores pueden estar relacionados con la orientación del gesto en el video que difiere de la mayoría de ejemplos del dataset.

Confianza mejor calibrada: Menor cantidad de “Impreciso” indica que el modelo produce salidas más seguras; las probabilidades están mejor separadas entre clases.

El dataset tiene la particularidad de que a pesar de que tiene muchas imágenes, le falta diversidad, creando una brecha entre imágenes estáticas y video. Aunque el modelo mostró métricas excelentes en imágenes estáticas (Etapa 1), en video el rendimiento cae notablemente. Esto sugiere problemas de *domain shift* (diferencias en ángulos, iluminación, movimiento, recortes y calidad del fotograma).

La ligera diferencia de rendimiento observada entre ResNet50 y MobileNetV2 puede atribuirse principalmente al impacto limitado del conjunto de capas descongeladas durante el proceso de fine-tuning en la primera arquitectura. Es posible que las capas seleccionadas para el ajuste no influyeran de manera significativa en la precisión final del modelo, por lo que identificar cuáles capas específicas aportan mayor relevancia al dominio de las señas podría representar una mejora sustancial en futuras iteraciones del entrenamiento.

En contraste, MobileNetV2 presenta una estructura más compacta, con una cantidad considerablemente menor de parámetros y capas. Esta característica facilita el ajuste de pesos sin incurrir en sobreentrenamiento, permitiendo que el modelo se adapte de manera más eficiente al conjunto de datos sin perder capacidad de generalización.

Conclusión

Las pruebas de la Etapa 3 muestran que, aunque el modelo obtuvo métricas sobresalientes en imágenes estáticas (Etapa 1), su transferencia a video no es directa: la precisión estricta en las pruebas reales queda cerca del 65%, y solo sube a aproximadamente a 70% si se incluye la categoría de baja confianza (Impreciso). Hay un subconjunto claro de letras (D, N, Z, C, J, M, O, P, Q) que requieren intervención prioritaria. Las recomendaciones anteriores (data augmentation focalizado, fine-tuning con frames de video, y ajuste de la etapa de smoothing/calibración) ofrecen un plan de trabajo concreto para cerrar la brecha entre desempeño en imágenes y desempeño en video.

Las estrategias de entrenamiento y fine-tuning influyen de manera directa en la adaptación del modelo: el número y tipo de capas descongeladas, el ritmo de aprendizaje y la calibración de las probabilidades afectan la forma en que la red ajusta sus pesos a nuevas condiciones visuales.

Finalmente, la arquitectura base determina el equilibrio entre capacidad de representación y eficiencia: ResNet50, más profunda y compleja, puede requerir una selección más cuidadosa de capas a afinar, mientras que MobileNetV2, más liviana, facilita la adaptación rápida sin incurrir en sobreentrenamiento.

Para lograr una interpretación robusta del lenguaje de señas en entornos reales, resulta indispensable explorar arquitecturas diseñadas específicamente para video, capaces de capturar la información temporal además de la espacial. Entre ellas se destacan las redes 3D-CNN, las LSTM convolucionales o los enfoques basados en Transformers espaciales-temporales.

El empleo de este tipo de arquitecturas abriría la posibilidad de incorporar gestos no estáticos, como aquellos presentes fuera del alfabeto manual: por ejemplo, signos que dependen de trayectorias o transiciones entre posiciones.